

**UNIVERSITÉ DU QUÉBEC**

**MÉMOIRE PRÉSENTÉ À  
L'UNIVERSITÉ DU QUÉBEC À TROIS-RIVIÈRES**

**COMME EXIGENCE PARTIELLE DE LA MAÎTRISE EN MATHÉMATIQUES ET  
INFORMATIQUE APPLIQUÉES**

**PAR  
TAKAM AXEL FRANK**

**ÉVALUATION AUTOMATISÉE DES DOMMAGES AUTOMOBILES A  
L'AIDE DE DEUX DETECTEURS DETR ET D'UN MODULE DE  
LOGIQUE FLOUE**

**MARS 2026**

**UNIVERSITE DU QUEBEC A TROIS-RIVIERES  
SERVICE DE LA BIBLIOTHEQUE**

# **Avertissement**

L'auteur de ce mémoire a autorisé l'Université du Québec à Trois-Rivières à diffuser, à des fins non lucratives, une copie de ce mémoire.

Cette diffusion n'entraîne pas une renonciation de la part de l'auteur à ses droits de propriété intellectuelle, incluant le droit d'auteur, sur ce mémoire. Notamment, la reproduction ou la publication de la totalité ou d'une partie importante de ce document requiert son autorisation.

# Dédicace

À ma famille, pour son soutien constant, sa patience et la confiance qu'elle m'a toujours accordée.

Je dédie ce mémoire à toutes les personnes qui ont cru en moi pendant ce parcours, et qui m'ont encouragé à persévérer jusqu'à l'aboutissement de ce travail.

# Remerciements

Je tiens à remercier chaleureusement toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce mémoire.

Je remercie tout particulièrement mes encadrants et les partenaires du milieu de stage pour leurs conseils, leur disponibilité et la confiance accordée tout au long du projet.

J'exprime également ma gratitude à ma famille et à mes proches pour leur soutien moral, leur compréhension et leurs encouragements constants pendant cette période exigeante.

Enfin, je remercie les collaborateurs techniques et académiques qui ont contribué à la constitution du corpus, à l'annotation des images et aux échanges scientifiques qui ont enrichi ce travail.

# Résumé

Ce mémoire présente DIRF-R, un pipeline d'évaluation automatisée des dommages automobiles fondé sur quatre étapes explicitement séparées : Detection, Intersection, Ratio et Fuzzy Reasoning. L'approche repose sur deux détecteurs DETR entraînés séparément, l'un pour les pièces du véhicule et l'autre pour les zones de dommages. Les sorties des deux détecteurs sont ensuite associées par une mesure géométrique réelle d'intersection, calculée par l'Intersection over Union, afin de déterminer quelles pièces sont touchées. Cette association permet d'estimer, pour chaque pièce, un Damage Ratio représentant la proportion de surface atteinte. Enfin, un module de logique floue interprète ce ratio de manière graduelle pour attribuer un niveau de gravité plus proche d'un raisonnement d'expertise que d'une décision binaire rigide.

Le jeu de données utilisé dans ce travail comprend plus de 700 images de véhicules intacts et endommagés, constituées au Canada en collaboration avec Progi et l'Université Stanford. Chaque image a été annotée manuellement via la plateforme Roboflow selon une taxonomie structurée des pièces automobiles et des zones de dommages. Les annotations ont été exportées sous forme de boîtes englobantes et utilisées pour entraîner séparément les deux branches de détection.

Les résultats quantitatifs montrent que le détecteur des dommages obtient les meilleures performances, avec un  $mAP@0,5$  de 0,759, un  $mAP@50:95$  de 0,452 et un score F1 de 0,505, tandis que le détecteur des pièces atteint respectivement 0,558, 0,289 et 0,312. Au-delà de ces métriques de détection, l'apport principal de DIRF-R réside dans l'enchaînement cohérent entre détection, association géométrique, quantification locale et interprétation floue. L'architecture proposée améliore ainsi l'explicabilité du système et le rend plus proche des besoins de l'assurance automobile et de l'expertise technique.

**Mots-clés :** DETR, logique floue, dommages automobiles, vision par ordinateur, IoU, Damage Ratio, raisonnement flou, évaluation automatisée.

# Abstract

This thesis presents DIRF-R, an automated vehicle damage assessment pipeline built around four explicitly separated stages: Detection, Intersection, Ratio, and Fuzzy Reasoning. The method relies on two independently trained DETR detectors, one dedicated to vehicle parts and the other to damage regions. Their predictions are associated through a geometric overlap measure based on Intersection over Union in order to determine which parts are affected. This association makes it possible to compute, for each part, a Damage Ratio representing the proportion of impacted surface. A fuzzy logic module then interprets this ratio progressively and assigns a severity level that is closer to expert reasoning than to a rigid binary decision.

The dataset used in this work contains more than 700 annotated images of intact and damaged vehicles and was assembled in Canada in collaboration with Progi and Stanford University. Each image was manually annotated in Roboflow using a structured taxonomy of vehicle parts and damage regions. Bounding-box annotations were then exported and used to train the two detection branches separately.

Quantitative results show that the damage detector achieves the strongest performance, with  $mAP@0.5$  of 0.759,  $mAP@50:95$  of 0.452, and F1-score of 0.505, while the parts detector reaches 0.558, 0.289, and 0.312 respectively. Beyond detection metrics, the main contribution of DIRF-R lies in the coherent chaining of detection, geometric association, local quantification, and fuzzy interpretation. The proposed architecture therefore improves interpretability and makes the system more relevant for insurance workflows and technical appraisal.

**Keywords:** DETR, fuzzy logic, vehicle damage assessment, computer vision, IoU, Damage Ratio, fuzzy reasoning, automated evaluation.

# Acronymes

- AP : Average Precision
- CBNet : Composite Backbone Network
- COCO : Common Objects in Context
- CNN : Convolutional Neural Network
- DETR : DEtection TRansformer
- DIRF-R : Detection–Intersection–Ratio–Fuzzy Reasoning
- F1-score : moyenne harmonique de la précision et du rappel
- FN : False Negative
- FP : False Positive
- GCNet : Global Context Network
- GPU : Graphics Processing Unit
- HTC : Hybrid Task Cascade
- IoU : Intersection over Union
- mAP@0,5 : mean Average Precision à un seuil d'IoU de 0,5
- mAP@50:95 : mean Average Precision calculé sur plusieurs seuils d'IoU de 0,50 à 0,95
- PANet : Path Aggregation Network
- R-CNN : Region-based Convolutional Neural Network
- ROI : Region of Interest
- TP : True Positive

# Table des matières

|                                               |    |
|-----------------------------------------------|----|
| Dédicace                                      | 3  |
| Remerciements                                 | 4  |
| Résumé                                        | 5  |
| Abstract                                      | 7  |
| Acronymes                                     | 9  |
| Table des matières                            | 10 |
| Liste des figures                             | 12 |
| Liste des tableaux                            | 13 |
| CHAPITRE 1 – Introduction                     | 14 |
| CHAPITRE 2 – État de l’art                    | 20 |
| CHAPITRE 3 – Méthodologie proposée            | 28 |
| CHAPITRE 4 – Expérimentations                 | 40 |
| CHAPITRE 5 – Résultats                        | 49 |
| CHAPITRE 6 – Menaces à la validité de l’étude | 53 |
| CHAPITRE 7 – Conclusion                       | 56 |
| Références                                    | 59 |
| Annexes                                       | 61 |





# Liste des figures

|          |                                                          |    |
|----------|----------------------------------------------------------|----|
| Figure 1 | Architecture interne de DETR                             | 29 |
| Figure 2 | Vue synthétique du pipeline DIRF-R                       | 32 |
| Figure 3 | Distinction exploratoire gauche/droite                   | 37 |
| Figure 4 | Fonctions d'appartenance floues de gravité               | 34 |
| Figure 5 | Projection d'une valeur sur les fonctions d'appartenance | 34 |
| Figure 6 | Sortie brute conjointe des détecteurs                    | 46 |
| Figure 7 | Pourcentages de dommages par pièces détectées            | 51 |

# Liste des tableaux

|           |                                                                      |    |
|-----------|----------------------------------------------------------------------|----|
| Tableau 1 | Classes annotées pour les branches Pièces et Dommages                | 47 |
| Tableau 2 | Résultats quantitatifs des deux détecteurs DETR utilisés dans DIRF-R | 52 |

# CHAPITRE 1 – Introduction

## 1.1 Contexte général

L'évaluation automatisée des dommages automobiles constitue aujourd'hui un enjeu stratégique pour les compagnies d'assurance, les ateliers de carrosserie, les experts techniques et, plus largement, tous les acteurs engagés dans la gestion numérique des sinistres. Dans les pratiques traditionnelles, l'état d'un véhicule est encore très souvent estimé à partir d'une inspection humaine, réalisée sur place ou à distance à partir d'images. Cette méthode reste pertinente sur le plan métier, mais elle présente plusieurs limites : elle dépend fortement de l'expérience de l'expert, elle nécessite du temps, elle engendre des coûts d'opération élevés et elle peut varier d'un évaluateur à un autre. À grande échelle, cette variabilité devient problématique, notamment lorsque les entreprises souhaitent uniformiser les processus d'estimation, réduire les délais de traitement et documenter les décisions de manière cohérente.

Dans le même temps, la disponibilité massive d'images issues de déclarations de sinistres, d'applications mobiles, d'inspections en atelier ou de bases de données internes a ouvert la voie à des méthodes d'analyse automatisée par vision par ordinateur. Les réseaux de neurones profonds ont permis des avancées majeures dans la détection d'objets, la segmentation et la classification visuelle [1]–[3]. Toutefois, les dommages automobiles représentent un cas d'usage particulièrement exigeant. Les pièces visibles varient selon l'angle de vue, les reflets de la carrosserie peuvent masquer une altération, les dommages peuvent être partiels, subtils ou très localisés, et plusieurs véhicules peuvent parfois apparaître dans la même image. En pratique, un système utile ne doit pas seulement repérer des boîtes englobantes ; il doit aussi être capable de relier les dommages détectés aux pièces réellement touchées et d'en proposer une interprétation intelligible.

Dans ce contexte, les détecteurs à base de Transformers, et plus particulièrement DETR, offrent une perspective intéressante. DETR reformule la détection d'objets comme une prédiction d'ensemble de bout en bout, fondée sur l'attention globale et l'appariement bipartite optimal. Cette architecture est particulièrement adaptée aux scènes où plusieurs éléments doivent être détectés simultanément sans dépendre d'ancres prédéfinies ni de nombreuses heuristiques de post-traitement. Néanmoins, même une bonne détection ne suffit pas à produire une expertise exploitable. Il faut encore déterminer l'intersection entre pièces et dommages, quantifier la proportion de surface affectée et transformer cette quantité en un niveau de gravité interprétable.

## 1.2 Problématique de recherche

La problématique centrale de ce mémoire peut être formulée de la manière suivante : comment concevoir un système d'analyse d'images automobiles capable non seulement de détecter les pièces et les dommages, mais aussi d'associer correctement ces deux niveaux d'information afin de produire une évaluation graduelle, cohérente et compréhensible de l'état du véhicule ?

Cette question comporte plusieurs difficultés scientifiques et méthodologiques. Premièrement, la détection des pièces et la détection des dommages ne relèvent pas exactement du même problème. Les pièces du véhicule correspondent à des composants structurels ayant des formes relativement connues, tandis que les dommages sont des altérations visuelles plus irrégulières, parfois peu contrastées ou de faible taille. Deuxièmement, la simple présence simultanée d'une pièce et d'un dommage dans une image ne permet pas d'affirmer automatiquement que cette pièce est endommagée. Il faut une étape explicite d'association géométrique. Troisièmement, une fois cette association établie, le système doit encore traduire un recouvrement spatial en une notion de sévérité. Or, les seuils rigides de type « présent / absent » ou « faible / fort » ne rendent pas correctement compte de l'incertitude visuelle et de la progressivité des dommages.

Un mémoire orienté exclusivement vers la détection aurait donc laissé de côté la partie la plus proche du raisonnement d'expertise. À l'inverse, un raisonnement flou appliqué sans base de détection suffisamment robuste aurait produit des décisions peu fiables. Le défi est donc double : disposer d'une base de détection cohérente et construire, au-dessus d'elle, un mécanisme d'interprétation qui reste simple, explicable et compatible avec les besoins d'un contexte applicatif réel.

## 1.3 Objectifs du mémoire

L'objectif général de ce travail est de proposer un pipeline complet, nommé DIRF-R (Detection–Intersection–Ratio–Fuzzy Reasoning), pour l'évaluation automatisée des dommages automobiles à partir d'images. Ce pipeline repose sur deux détecteurs DETR entraînés séparément, sur une association géométrique fondée sur l'Intersection over Union, sur le calcul d'un Damage Ratio local par pièce, puis sur un module de logique floue destiné à interpréter progressivement la gravité.

Plus précisément, les objectifs spécifiques sont les suivants. D'abord, il s'agit de construire une branche de détection dédiée aux pièces du véhicule, capable d'identifier les principaux composants visibles d'un véhicule dans une image. Ensuite, il s'agit de construire

une seconde branche, indépendante, dédiée à la localisation des zones de dommages. Le troisième objectif consiste à relier les sorties de ces deux détecteurs par une mesure d'intersection réelle, afin de savoir quelles pièces sont touchées et dans quelle proportion. Le quatrième objectif est de convertir cette information géométrique en une représentation quantitative simple, le Damage Ratio, puis en une interprétation sémantique graduelle via la logique floue. Enfin, le dernier objectif consiste à évaluer la pertinence de cette architecture sur un jeu de données réel et à montrer en quoi elle améliore l'explicabilité du processus d'évaluation.

## **1.4 Contributions principales**

Les contributions de ce mémoire se situent à l'interface entre détection d'objets, analyse géométrique et raisonnement flou. La première contribution est la formalisation d'un pipeline clair en quatre étapes — détection, intersection, ratio et raisonnement flou — qui rend explicite le rôle de chaque composant. La deuxième contribution est l'utilisation de deux détecteurs DETR spécialisés et entraînés séparément, ce qui évite de confondre la structure du véhicule et la localisation des dommages. La troisième contribution est l'introduction d'un Damage Ratio comme variable intermédiaire simple et interprétable, directement reliée à la proportion de surface d'une pièce touchée par un dommage. La quatrième contribution réside dans l'usage de la logique floue comme couche terminale d'interprétation, sans modification de l'apprentissage des détecteurs eux-mêmes. Cette séparation méthodologique rend l'architecture plus lisible pour un lecteur non spécialiste et plus défendable devant un jury.

Au-delà de ces éléments techniques, le travail apporte aussi une contribution méthodologique. Il montre qu'il est possible de construire une chaîne de traitement cohérente sans recourir à une accumulation d'heuristiques opaques. Le système ne se limite pas à une liste de détections ; il produit une lecture structurée de l'état du véhicule, pièce par pièce, puis au niveau global. Cette propriété est importante dans les contextes où la confiance dans la décision et la possibilité d'expliquer le résultat important autant que la performance brute.

## **1.5 Organisation du mémoire**

Le reste du document est structuré de la manière suivante. Le chapitre 2 présente l'état de l'art. Il traite des approches de détection des dommages, des méthodes de segmentation et de localisation, des limites en conditions réelles, de l'apport des modèles à base de Transformers et de l'intérêt de la logique floue, en cohérence avec le positionnement scientifique de ce travail.

Le chapitre 3 détaille la méthodologie proposée et présente le pipeline DIRF-R. Il expose d'abord les principes de DETR, puis la place exacte du module flou, avant de décrire successivement les quatre étapes du pipeline : Detection, Intersection, Ratio et Fuzzy Reasoning. Ce chapitre introduit également les mécanismes complémentaires utilisés pour l'isolation du véhicule principal, la stabilisation géométrique des détections et l'attribution gauche/droite des pièces.

Le chapitre 4 décrit le jeu de données, les choix d'annotation, les outils mobilisés, le protocole expérimental et les métriques retenues. Le chapitre 5 présente les résultats quantitatifs obtenus par les deux détecteurs DETR et les interprète à la lumière du pipeline complet. Le chapitre 6 discute les principales menaces à la validité de l'étude. Enfin, le chapitre 7 conclut le mémoire et présente plusieurs pistes d'amélioration et d'extension.

## **1.6 Délimitation du travail**

Ce mémoire se concentre sur l'évaluation visuelle des dommages externes à partir d'images 2D annotées par boîtes englobantes. Il ne vise pas la reconstruction 3D du véhicule, l'estimation du coût de réparation, la détection de dommages internes ou la classification fine des types de dommages selon des catégories expertes détaillées. La branche dommages utilise volontairement une seule classe, afin de préserver la cohérence entre l'objectif de localisation et le rôle du module flou dans l'évaluation de gravité.

Cette délimitation renforce la lisibilité du travail. Elle évite d'attribuer au système des prétentions qu'il n'a pas. Le mémoire ne cherche pas à remplacer l'expert humain dans toute la chaîne de décision ; il propose une architecture d'aide à l'analyse, capable de structurer les informations visuelles et d'en fournir une lecture graduelle. Ce cadrage est essentiel pour interpréter correctement les résultats et pour situer les perspectives futures.

# CHAPITRE 2 – État de l’art

## 2.1 Introduction générale sur l’état de l’art

L’automatisation de l’estimation des dommages sur les véhicules mobilise plusieurs objectifs complémentaires : détecter les zones endommagées, identifier les pièces concernées, relier correctement les dommages aux composants touchés, puis produire une estimation de gravité suffisamment fiable pour être utile en contexte applicatif. La littérature dans ce domaine est abondante, mais elle reste fragmentée. Certains travaux se concentrent sur la classification de dommages, d’autres sur la segmentation de pièces, d’autres encore sur la robustesse en conditions réelles ou sur l’interprétation des sorties du modèle. Pour situer correctement l’approche proposée dans ce mémoire, il est nécessaire de parcourir ces contributions en distinguant ce qu’elles apportent et ce qu’elles laissent encore en suspens.

Ce chapitre présente les familles d’approches les plus pertinentes pour DIRF-R : les travaux de détection et de classification des dommages, les approches de segmentation et de localisation des pièces, les enjeux de robustesse en conditions réelles, l’émergence des détecteurs à base de Transformers, puis l’apport de la logique floue pour l’interprétation. Le positionnement retenu ici s’appuie sur DETR et sur le raisonnement flou comme base méthodologique de la solution proposée.

### 2.1.1 Travaux connexes sur la détection et la classification des dommages

Les premières recherches sur les dommages automobiles se sont principalement appuyées sur des réseaux convolutionnels de classification ou sur des détecteurs d’objets conventionnels. Leur objectif était soit d’identifier le type de dommage présent dans une image, soit de localiser des zones altérées à l’aide de boîtes englobantes. Ces travaux ont montré que l’apprentissage profond pouvait capturer des motifs visuels pertinents, comme les rayures, les bosses, les fissures ou les déformations localisées, à condition de disposer de jeux de données annotés de taille suffisante.

Un premier ensemble de travaux a porté sur la classification des dommages en plusieurs catégories. Les réseaux de type CNN y sont entraînés à partir d’images de véhicules accidentés ou non accidentés, puis évalués sur leur capacité à reconnaître des motifs visuels liés à des défauts spécifiques. Ces approches ont permis d’atteindre de bons scores de précision dans des environnements relativement contrôlés, notamment lorsqu’un transfert d’apprentissage depuis ImageNet était utilisé. Elles ont aussi montré qu’une augmentation de



données adaptée, combinant rotation, zoom, symétrie, variation de luminosité ou flou modéré, pouvait améliorer la généralisation. Néanmoins, leur principale limite réside dans le fait qu'elles apprennent souvent à reconnaître un état global de l'image, plutôt qu'à relier explicitement un dommage à une pièce du véhicule.

Un second ensemble de travaux s'est tourné vers la détection des dommages à l'aide de boîtes englobantes. L'avantage de cette stratégie est qu'elle produit une localisation plus opérationnelle que la simple classification. Cependant, les résultats restent fortement dépendants de la qualité des annotations, de la variété des angles de prise de vue et de la distribution des classes. Les dommages discrets, peu contrastés ou partiellement visibles sont souvent sous-détectés. De plus, lorsque la tâche implique plusieurs types de dommages ou plusieurs composants dans une même image, les faux positifs et les ambiguïtés spatiales augmentent rapidement.

La littérature met donc en évidence un premier constat : localiser une zone de dommage ne suffit pas pour une expertise utile. Un système pertinent doit aussi comprendre la structure du véhicule, autrement dit savoir sur quelle pièce le dommage apparaît. Cette exigence explique pourquoi les travaux sur la segmentation et la localisation des pièces occupent une place importante dans l'état de l'art.

### **2.1.2 Travaux connexes sur la segmentation et la localisation des pièces et des dommages**

L'identification des pièces du véhicule a donné lieu à plusieurs travaux fondés sur la segmentation sémantique et l'instance segmentation. Des architectures comme Mask R-CNN, HTC, PANet, CBNet ou GCNet ont été évaluées sur des ensembles d'images annotées contenant des pièces telles que les portières, les ailes, les vitres, les phares, les rétroviseurs ou les pare-chocs. Ces études ont montré qu'une modélisation plus fine du contour des objets améliore la compréhension structurale du véhicule, notamment lorsque plusieurs composants se chevauchent partiellement ou que les conditions de prise de vue sont complexes.

Les résultats les plus intéressants de cette famille de travaux concernent la possibilité d'annoter les pièces avec une granularité assez fine, y compris la distinction entre côté gauche et côté droit. Cette précision topologique devient précieuse lorsqu'on cherche à associer un dommage à un composant précis. En revanche, ces méthodes ont souvent un coût computationnel élevé, et leurs performances se dégradent lorsque le jeu de données est limité ou très déséquilibré. En outre, beaucoup de travaux se concentrent sur la structure visible du véhicule, sans relier explicitement cette structure à des zones de dommages.

D'autres recherches ont proposé des systèmes à double branche, une première pour repérer les côtés ou les composants du véhicule, et une seconde pour localiser les altérations visuelles. L'intérêt de cette séparation est méthodologiquement proche de celui retenu dans DIRF-R : au lieu d'entraîner un système à tout faire en une seule étape, on distingue la structuration du véhicule de la détection des dommages. Cette dissociation facilite ensuite l'interprétation, car elle permet de relier explicitement une zone endommagée à une pièce donnée. Toutefois, dans la majorité de ces travaux, l'étape d'association reste peu formalisée. Elle repose souvent sur des heuristiques implicites, sur une proximité spatiale non justifiée ou sur un simple recouvrement observé à l'œil.

Pour notre problématique, la leçon essentielle de ces travaux est la suivante : une bonne évaluation des dommages automobiles exige de combiner la localisation des altérations avec une représentation structurée des pièces. Le simple repérage de zones anormales ne suffit pas ; il faut encore construire une relation explicite entre ces zones et les composants du véhicule.

### **2.1.3 Travaux connexes pour la robustesse et les performances en conditions réelles**

Un autre axe majeur de la littérature concerne la robustesse des systèmes en conditions réelles. Les images utilisées dans les sinistres automobiles sont rarement produites dans un environnement parfaitement contrôlé. Les véhicules peuvent être photographiés à l'extérieur ou dans un atelier, sous des éclairages variables, avec des reflets intenses, des zones d'ombre, de la pluie, du brouillard, des arrière-plans chargés ou d'autres véhicules à proximité. Dans ce type de contexte, plusieurs méthodes qui fonctionnent bien sur un jeu de données propre perdent rapidement en précision.

Certaines études ont montré que les réflexions spéculaires sur la carrosserie trompent facilement les modèles, en particulier lorsque ceux-ci apprennent des corrélations visuelles superficielles plutôt qu'une vraie géométrie des dommages. D'autres ont mis en évidence la fragilité des systèmes face aux petits objets ou aux dommages partiels. Une légère variation d'angle suffit parfois à modifier fortement la détection. Enfin, la présence simultanée de plusieurs véhicules dans une image peut conduire le modèle à attribuer des pièces secondaires au véhicule principal, ce qui perturbe l'évaluation globale.

Ces observations sont importantes pour le présent travail, car elles justifient l'ajout de mécanismes complémentaires autour des détecteurs. L'isolation du véhicule principal, la consolidation des détections redondantes et la cohérence gauche/droite ne sont pas des raffinements accessoires ; elles répondent directement à des limites observées dans la

littérature et dans les applications concrètes. Un modèle utile doit donc être pensé comme une chaîne complète de traitement et non comme un seul algorithme de détection isolé.

#### **2.1.4 Travaux connexes concernant les modèles à base de Transformers et les approches efficaces**

L'introduction des Transformers en vision par ordinateur a marqué une évolution importante dans la détection d'objets. DETR, proposé par Carion et al., a reformulé la détection comme une tâche de prédiction d'ensemble de bout en bout, associant les prédictions aux annotations par appariement bipartite optimal. Cette formulation a simplifié le pipeline en supprimant plusieurs heuristiques classiques, notamment la dépendance aux ancres prédéfinies et la multiplication des étapes de post-traitement. L'un des principaux avantages de DETR tient à sa capacité de modélisation globale : l'attention lui permet d'exploiter le contexte complet de l'image, ce qui est particulièrement utile lorsque plusieurs pièces et plusieurs dommages coexistent.

La première version de DETR présentait néanmoins deux limites bien connues : une convergence lente et une sensibilité aux petits objets. Ces difficultés ont motivé l'apparition de variantes comme Deformable DETR, DAB-DETR, DN-DETR ou Conditional DETR. Deformable DETR concentre l'attention sur un nombre restreint de points pertinents à différentes échelles, ce qui améliore la vitesse de convergence et la prise en compte des objets de petite taille. DAB-DETR introduit des requêtes dynamiques guidées par des boîtes, fournissant au décodeur des repères spatiaux plus explicites. DN-DETR accélère l'apprentissage en ajoutant une stratégie de débruitage des requêtes. Conditional DETR, de son côté, propose un mécanisme où chaque requête apprend à se focaliser plus efficacement sur une région spécifique de l'image.

Ces variantes n'ont pas pour effet d'annuler l'intérêt du modèle original ; elles montrent plutôt qu'un cadre Transformer est suffisamment riche pour être adapté à des cas d'usage exigeants. Pour notre mémoire, elles jouent deux rôles. D'une part, elles confirment la pertinence d'un positionnement DETR pour analyser la structure d'un véhicule et les zones de dommages. D'autre part, elles rappellent que les métriques de détection ne suffisent pas, à elles seules, à fournir une expertise. Même un excellent détecteur produit des sorties numériques qui demandent ensuite à être interprétées.

#### **2.1.5 Apport de la logique floue et synthèse des lacunes**

La logique floue apporte précisément ce niveau d'interprétation. Depuis les travaux fondateurs de Zadeh, elle est utilisée pour modéliser des phénomènes graduels, ambigus ou

partiellement vrais. Dans un système flou, une variable ne bascule pas brutalement d'une catégorie à une autre ; elle peut appartenir à plusieurs catégories avec des degrés différents. Cette propriété est particulièrement utile lorsque l'on cherche à traduire un indicateur continu — par exemple la proportion de surface d'une pièce affectée — en niveaux de gravité compréhensibles.

Dans le domaine de la vision par ordinateur, la logique floue a déjà été exploitée pour améliorer la segmentation, fusionner plusieurs indices ou interpréter des sorties incertaines. Des travaux appliqués aux dommages automobiles montrent qu'elle peut aider à mieux distinguer un dommage léger d'un dommage modéré, ou à mieux traiter des situations où les indices visuels sont faibles. Son intérêt principal n'est pas de remplacer la détection, mais de compléter celle-ci par une étape de décision plus progressive et plus explicable.

La synthèse de la littérature met donc en évidence quatre lacunes majeures. Premièrement, beaucoup de travaux détectent les dommages sans représenter clairement la structure du véhicule. Deuxièmement, lorsqu'une structuration existe, l'association entre pièce et dommage reste souvent implicite ou insuffisamment justifiée. Troisièmement, les conditions réelles de prise de vue dégradent rapidement la fiabilité des prédictions. Quatrièmement, la gravité du dommage est encore fréquemment abordée comme une décision rigide, alors qu'elle relève davantage d'une interprétation graduelle. C'est précisément pour répondre à ces limites que nous proposons DIRF-R : un pipeline basé sur deux détecteurs DETR spécialisés, une association géométrique explicite par IoU, un Damage Ratio simple à calculer, puis une interprétation floue de la gravité.

### **2.1.6 Positionnement spécifique de DIRF-R**

Au regard de cette revue, le positionnement de DIRF-R peut être résumé en trois choix. Le premier est un choix de structure : plutôt qu'un modèle unique supposé résoudre simultanément toutes les dimensions du problème, nous retenons deux détecteurs spécialisés et une chaîne d'interprétation explicite. Le deuxième est un choix de représentation : la relation entre une pièce et un dommage est fondée sur une mesure géométrique simple, calculable et vérifiable, à savoir l'IoU. Le troisième est un choix de décision : la gravité n'est pas fixée par une règle dure, mais par une interprétation floue du Damage Ratio.

Ce positionnement s'inscrit dans la continuité de l'état de l'art tout en s'en distinguant clairement. Il s'inspire des travaux sur la structuration des pièces, des travaux sur la détection de dommages et des travaux sur la gestion de l'incertitude, mais il les articule dans un pipeline unique. C'est cette articulation qui constitue la singularité du mémoire : au lieu d'ajouter un

module flou directement dans le détecteur, ou d'utiliser un score global difficile à interpréter, DIRF-R conserve une chaîne d'étapes simples, chacune justifiable indépendamment.

### **2.1.7 Ce que le chapitre 2 justifie pour la suite du mémoire**

Ce chapitre justifie directement les choix du chapitre méthodologique. La littérature montre que la détection des dommages et la structuration des pièces sont deux problèmes liés mais distincts ; elle montre également qu'une bonne base de détection n'élimine pas la question de l'interprétation. Elle met enfin en évidence le besoin d'une méthode capable de rester lisible et défendable en conditions réelles. Ces constats préparent naturellement le lecteur à la logique de DIRF-R.

Autrement dit, l'état de l'art n'est pas ici un simple inventaire de travaux. Il sert à montrer pourquoi la combinaison DETR + association géométrique + logique floue constitue une réponse méthodologiquement cohérente. Cette cohérence est précisément ce que la suite du mémoire cherchera à formaliser puis à évaluer.

# CHAPITRE 3 – Méthodologie proposée

## 3.1 DETR (DEtection TRansformer) comme base de détection

Dans ce travail, la base de détection repose sur DETR, proposé par Carion et al. comme un modèle de détection d'objets de bout en bout fondé sur les Transformers [1], [3]. L'intérêt de DETR, pour notre problématique, tient à sa capacité à traiter l'image comme une scène globale plutôt que comme une simple juxtaposition de régions locales. Là où des architectures plus anciennes s'appuient fortement sur des ancres prédéfinies et des heuristiques de suppression des doublons, DETR apprend directement à produire un ensemble cohérent de prédictions.

Le principe général peut être résumé simplement. Une image est d'abord transformée en une représentation visuelle compacte à l'aide d'un backbone convolutionnel. Cette représentation est ensuite transmise à un encodeur Transformer, qui modélise les relations globales entre toutes les régions de l'image. Un décodeur Transformer manipule ensuite un ensemble fixe de requêtes d'objets apprises. Chaque requête correspond à une hypothèse d'objet potentiel. À la sortie, le modèle produit des classes et des boîtes englobantes normalisées. Pendant l'apprentissage, un appariement bipartite optimal garantit qu'une prédiction donnée correspond au plus à un objet annoté, ce qui réduit naturellement les doublons.

Dans le contexte de l'analyse automobile, cette propriété est précieuse. Une image de véhicule contient souvent plusieurs composants visuellement proches, parfois partiellement occultés ou déformés par la perspective. Un modèle qui raisonne avec une vision globale de la scène peut mieux prendre en compte la cohérence structurelle entre les pièces. C'est pourquoi DETR constitue ici le socle de la phase Detection de DIRF-R.

### 3.1.1 Architecture interne de DETR

L'architecture interne de DETR peut être décrite à travers quatre blocs principaux : le backbone convolutionnel, l'encodeur Transformer, le décodeur Transformer et la tête de prédiction. Le backbone, souvent de type ResNet, extrait des caractéristiques visuelles à partir de l'image brute. L'encodeur Transformer reçoit ensuite ces caractéristiques, enrichies par un codage positionnel, et apprend des dépendances globales entre les différentes régions de l'image. Le décodeur manipule un nombre fixe de requêtes d'objets, qui sont affinées couche après couche. Enfin, la tête de prédiction produit, pour chaque requête, une classe et une boîte englobante.

Pour un lecteur non spécialiste, il est utile de retenir trois idées. Premièrement, DETR ne parcourt pas l'image de manière purement locale ; il construit une représentation de scène. Deuxièmement, le modèle apprend à gérer un ensemble d'objets plutôt qu'une séquence ordonnée. Troisièmement, l'apprentissage par appariement bipartite lui permet de simplifier la phase d'inférence en limitant le recours à des heuristiques externes.




Figure 1 : Architecture de DETR.

### 3.1.2 Deux détecteurs spécialisés dans DIRF-R

DIRF-R n'utilise pas un seul détecteur pour toutes les tâches. Le pipeline repose sur deux détecteurs DETR distincts et entraînés séparément. Le premier est spécialisé dans la détection des pièces du véhicule. Son rôle est d'identifier les composants structurels visibles, tels que les portières, les ailes, le capot, les phares, le pare-brise ou les rétroviseurs. Le second détecteur est spécialisé dans la localisation des dommages et ne travaille que sur une seule classe : « Endommagée ».

Cette séparation est essentielle pour préserver la clarté méthodologique du système. Les pièces et les dommages ne possèdent ni la même stabilité géométrique ni la même régularité visuelle. Les pièces ont des formes plus récurrentes et une structure relativement stable ; les dommages, eux, peuvent être diffus, très localisés, partiellement visibles ou de forme irrégulière. En dissociant les deux tâches, on laisse à chaque détecteur la possibilité d'apprendre sa propre distribution sans le forcer à résoudre plusieurs problèmes hétérogènes simultanément.

Ainsi, la phase Detection de DIRF-R ne doit pas être comprise comme une détection globale unique, mais comme la combinaison ordonnée de deux inférences indépendantes, dont les sorties seront ensuite rapprochées par l'étape d'Intersection.

## 3.2 Logique floue : concepts, intérêt et place dans le pipeline

La logique floue, introduite par Zadeh, constitue un cadre adapté à la modélisation de situations où la frontière entre les catégories n'est pas rigide [4], [5]. Dans une logique classique, une proposition est vraie ou fausse ; dans une logique floue, elle peut être vraie à un certain degré. Concrètement, cela signifie qu'une pièce peut être considérée à la fois « légèrement » et « modérément » endommagée avec des degrés d'appartenance différents, plutôt que d'être assignée brutalement à une seule catégorie.

Dans le cas des dommages automobiles, cette souplesse est particulièrement utile. Une faible variation de recouvrement entre une pièce et une zone de dommage ne devrait pas provoquer un saut brutal de décision. De plus, les conditions visuelles réelles introduisent de l'incertitude : un dommage peut être visible seulement sous un certain angle, une partie de la pièce peut être masquée, ou le contour exact du dommage peut rester imprécis. Une logique de seuils stricts reste alors trop pauvre pour traduire le raisonnement d'un expert.

Il faut toutefois souligner un point central pour la cohérence scientifique du mémoire : dans DIRF-R, la logique floue n'intervient ni dans l'apprentissage des deux détecteurs DETR, ni dans le calcul géométrique de l'intersection. Elle agit exclusivement après ces étapes, au moment de l'interprétation. Son rôle n'est donc pas de corriger un détecteur ou de remplacer l'IoU ; il consiste à transformer un indicateur continu, le Damage Ratio, en niveaux de gravité progressifs et plus explicables.

## 3.3 Vue d'ensemble du pipeline DIRF-R

Le nom DIRF-R résume exactement l'enchaînement retenu dans ce mémoire : Detection, Intersection, Ratio, Fuzzy Reasoning. Ce découpage a une valeur plus forte qu'un simple acronyme. Il matérialise une architecture où chaque étape repose sur une entrée claire, produit une sortie identifiable et joue un rôle méthodologiquement distinct.

La première étape, Detection, consiste à obtenir les prédictions des deux détecteurs DETR spécialisés : une liste de pièces et une liste de zones de dommages. La deuxième étape, Intersection, relie ces deux ensembles à l'aide d'une mesure géométrique réelle, l'Intersection over Union. La troisième étape, Ratio, transforme cette relation spatiale en une proportion de surface touchée par pièce. Enfin, la quatrième étape, Fuzzy Reasoning, interprète le ratio obtenu au moyen de règles et de fonctions d'appartenance floues pour produire des niveaux de gravité.



La grande force de cette organisation est la traçabilité. À tout moment, on peut expliquer le passage d'une image brute à une conclusion. On sait quelles pièces ont été détectées, quels dommages ont été localisés, quelle intersection a été calculée, quel ratio en découle et pourquoi le système aboutit à un niveau de gravité donné.




Figure 2 : Vue synthétique de l'architecture DIRF-R

### 3.4 Detection : sortie des détecteurs de pièces et de dommages

Pour une image d'entrée donnée, le détecteur des pièces retourne un ensemble de prédictions de la forme :

(pièce\_i, boîte\_i, confiance\_i)

Le détecteur des dommages retourne un ensemble plus simple :  
(dommage\_j, boîte\_j, confiance\_j)

Chaque boîte est définie par ses coordonnées dans l'image. À ce stade, le système sait où se trouvent les pièces et où se trouvent les dommages, mais il ne sait pas encore quelles pièces sont réellement affectées. C'est précisément ce manque d'information relationnelle qui justifie l'étape suivante.

La séparation des détecteurs apporte aussi un avantage analytique. Elle permet d'évaluer différemment les performances des deux branches. Une mauvaise détection de pièces n'a pas la même signification qu'une mauvaise détection de dommages. En distinguant les deux, on obtient une lecture plus fine des forces et des limites du pipeline.

### 3.5 Intersection : association géométrique explicite par IoU

L'étape d'association repose sur l'Intersection over Union, notée IoU. Cette mesure compare la surface d'intersection de deux boîtes à la surface de leur union. Pour une pièce  $P_i$  et un dommage  $D_j$ , on définit :

$$IoU(P_i, D_j) = Aire(P_i \cap D_j) / Aire(P_i \cup D_j)$$

Cette formule est volontairement simple. Elle ne cherche pas à produire un raisonnement flou ; elle mesure objectivement le recouvrement spatial entre une pièce et une zone de dommage. Si l'IoU est nulle, la pièce et le dommage ne se recouvrent pas. Si elle est positive, on dispose d'un indice clair qu'un lien spatial existe entre eux.

Dans DIRF-R, l'IoU n'est donc pas un critère d'évaluation externe uniquement utilisé pour calculer des métriques ; elle joue un rôle interne dans le pipeline. Elle sert à établir la relation entre structure et altération. Cette distinction est importante pour éviter une confusion fréquente : ici, l'IoU intervient comme mécanisme d'association pièce–dommage, alors que la logique floue n'intervient qu'après cette association.

### 3.6 Ratio : calcul du Damage Ratio local

Une fois l'association géométrique établie, il faut quantifier la proportion de la pièce réellement touchée. C'est le rôle du Damage Ratio. Pour une pièce  $P_i$  associée à une ou plusieurs zones de dommage, on définit :

$$DR_i = \frac{\text{Aire}(U_{j=1}^n(P_i \cap D_j))}{\text{Aire}(P_i)}$$

où  $(U_{j=1}^n(P_i \cap D_j))$  représente la zone de dommage ou l'union des zones de dommages retenues pour la pièce  $P_i$ .

Le Damage Ratio varie entre 0 et 1. Une valeur proche de 0 indique qu'une très petite portion de la pièce est affectée ; une valeur proche de 1 signifie qu'une part importante de sa surface visible est endommagée. Cette variable joue un rôle central dans DIRF-R, car elle assure la transition entre la géométrie et l'interprétation. Tant que l'on reste au niveau de l'IoU, on manipule une relation spatiale. Dès que l'on calcule le Damage Ratio, on dispose d'un indicateur directement exploitable pour raisonner sur la gravité du dommage.

Pour rendre le système plus compréhensible, on peut associer ce ratio à des exemples simples. Un Damage Ratio de 0,05 correspond à une atteinte très localisée, souvent visuellement faible. Un ratio autour de 0,25 peut correspondre à un dommage visible mais encore limité à une portion de la pièce. Un ratio supérieur à 0,50 traduit généralement une atteinte importante qui affecte une large zone de la pièce. Ces exemples ne remplacent pas le raisonnement flou ; ils en préparent l'interprétation.

### 3.7 Fuzzy Reasoning : interprétation graduelle de la gravité

Le Damage Ratio calculé à l'étape précédente constitue l'entrée principale du module flou. Dans sa forme la plus simple, ce module définit plusieurs catégories linguistiques de gravité, par exemple : mineur, modéré, sévère et très sévère. À chacune de ces catégories correspond une fonction d'appartenance. Une pièce donnée peut donc appartenir partiellement à plusieurs niveaux de gravité.

Le choix de fonctions d'appartenance triangulaires ou trapézoïdales permet de conserver une interprétation simple. Dans le cadre de ce mémoire, le raisonnement flou reste volontairement lisible. Il ne s'agit pas de construire un système d'inférence trop lourd, mais de fournir une couche de décision progressive. Par exemple, un Damage Ratio proche de 0,20

peut appartenir faiblement à la catégorie « mineur » et plus fortement à la catégorie « modéré ». Le système évite ainsi l'effet de seuil abrupt.




Figure 3 : Fonctions d'appartenance floues de gravité.




Figure 4 : Projection d'une valeur de sévérité sur les fonctions d'appartenance.

À titre d'approximation descriptive, on peut lire les niveaux de gravité selon les repères suivants :

- mineur : ratio faible ;
- modéré : ratio intermédiaire inférieur ;
- sévère : ratio intermédiaire supérieur ;
- très sévère : ratio élevé.

Ces repères n'ont pas vocation à remplacer les fonctions d'appartenance elles-mêmes. Ils servent à rendre le raisonnement lisible pour un lecteur humain. Le point important, scientifiquement, est que la décision finale ne repose pas sur une coupure binaire stricte, mais sur une interprétation progressive d'un indicateur continu.

### 3.8 Évaluation locale et globale

L'évaluation locale est produite pièce par pièce. Chaque pièce détectée reçoit un Damage Ratio et une interprétation floue de gravité. On obtient ainsi une description structurée du véhicule, du type : porte avant gauche modérément endommagée, pare-chocs avant sévèrement endommagé, aile droite intacte, etc. Cette granularité est particulièrement utile dans les contextes d'expertise, car elle permet de discuter des réparations composant par composant.

Pour obtenir une lecture globale de l'état du véhicule, il est possible d'agréger les ratios locaux. Une forme simple d'agrégation consiste à utiliser une moyenne pondérée :

$$ScoreGlobal = \frac{\sum_{i=1}^N w_i \times DR_i}{\sum_{i=1}^N w_i}$$

Où  $w_i$  représente le poids attribué à la pièce  $i$ . Dans ce mémoire, cette pondération est présentée comme une extension naturelle du pipeline. Elle permettrait, par exemple, de donner plus d'importance à des pièces structurales ou coûteuses à réparer qu'à des éléments secondaires. Même lorsque l'agrégation reste simple, elle rend possible une synthèse finale de l'état du véhicule sans perdre entièrement l'information locale.

### 3.9 Robustesse structurelle : isolation du véhicule principal et stabilisation

Dans des images réelles, le véhicule étudié n'est pas toujours seul. Il peut apparaître dans un stationnement, sur la voie publique ou devant un atelier, avec d'autres véhicules visibles en arrière-plan. Si le pipeline exploitait directement toutes les détections produites, des pièces appartenant à un véhicule secondaire pourraient être associées à des dommages du

véhicule principal, ou inversement. Pour éviter ce problème, DIRF-R intègre un mécanisme d'isolation du véhicule principal.

Le premier mécanisme repose sur une hypothèse de taille apparente. Les pièces du véhicule principal occupent généralement une surface plus importante dans l'image que celles des véhicules situés à l'arrière-plan. Un regroupement par aire permet alors d'identifier l'ensemble dominant. Le second mécanisme repose sur une région d'intérêt centrée. Dans les prises de vue standards, le véhicule à expertiser se trouve le plus souvent au centre du cadre. En combinant ces deux critères, on écarte une partie significative des détections parasites.


Une fois le véhicule principal isolé, il reste nécessaire de stabiliser les détections. Certaines pièces peuvent être détectées plusieurs fois ou partiellement fragmentées. Une consolidation géométrique permet de fusionner les boîtes très redondantes et d'éliminer des régions trop petites ou peu plausibles. Cette étape ne modifie pas le principe de DIRF-R ; elle assure simplement que l'étape d'intersection repose sur une représentation plus propre et plus cohérente de la scène.

### **3.10 Distinction gauche/droite des pièces**

La capacité à distinguer les côtés gauche et droit constitue un élément pratique important du pipeline. Dans un contexte d'assurance ou de réparation, il ne suffit pas de dire qu'une portière est endommagée ; il faut savoir s'il s'agit de la portière avant gauche, arrière droite, du rétroviseur droit ou de l'aile gauche. DIRF-R introduit donc une règle de classification latérale fondée sur la position horizontale du centre d'une pièce.

Soit  $x_c$  la coordonnée horizontale du centre de la pièce à classer et  $x_{ref}$  celle d'un point de référence central. Lorsque le pare-chocs avant ou un autre composant central robuste est disponible, son centre sert de référence. À défaut, on peut utiliser le centre de l'image. La décision s'écrit :

Cette composante doit toutefois être lue comme une étape exploratoire. Les essais montrent qu'elle fournit souvent une indication latérale utile, mais qu'elle reste sensible aux perspectives obliques, aux occlusions et aux erreurs de détection des pièces de référence. Une perspective future consistera donc à améliorer cette distinction gauche/droite à l'aide d'indices géométriques plus robustes.



Pièces endommagées détectées, pourcentages de dommages et catégories :

|                     |                   |                                   |
|---------------------|-------------------|-----------------------------------|
| Phare_avant_gauche: | 29.66% endommagé  | - Catégorie: Dommages moyens      |
| Aile_gauche:        | 100.00% endommagé | - Catégorie: Dommages très graves |
| Pare-brise:         | 72.73% endommagé  | - Catégorie: Dommages graves      |
| Aile_droite:        | 12.85% endommagé  | - Catégorie: Dommages mineurs     |
| Calandre:           | 33.93% endommagé  | - Catégorie: Dommages moyens      |
| Pare-brise:         | 84.94% endommagé  | - Catégorie: Dommages très graves |

*figure 5: Exemple exploratoire de distinction gauche/droite sur une image réelle.*

si  $x_c < x_{ref}$ , alors la pièce est classée à gauche ;  
sinon, elle est classée à droite.

Cette règle reste simple, mais elle suffit à renforcer la cohérence topologique du pipeline lorsque le véhicule est photographié dans des conditions standards. Sa valeur principale n'est pas la sophistication mathématique ; elle réside dans l'utilité métier de l'information produite.

### 3.11 Synthèse méthodologique

Le chapitre méthodologique peut donc se résumer ainsi. DIRF-R ne cherche pas à tout résoudre dans un seul bloc. Il sépare volontairement la détection des pièces, la détection des dommages, l'association géométrique, la quantification de la surface touchée et l'interprétation floue. Cette décomposition rend le système plus lisible, plus explicable et plus facilement défendable.

Surtout, elle permet d'éviter une erreur conceptuelle fréquente : confondre la détection avec la décision. Dans DIRF-R, les détecteurs fournissent une base visuelle ; l'IoU établit la relation spatiale ; le Damage Ratio quantifie l'atteinte ; la logique floue interprète. Chacune de ces étapes peut être justifiée séparément, ce qui constitue un atout important pour un mémoire visant à rester compréhensible pour un lecteur non spécialiste tout en conservant une cohérence technique solide.

### **3.12 Remarques sur la simplicité et la défendabilité du pipeline**

Une qualité importante de DIRF-R est sa simplicité conceptuelle. Dans beaucoup de systèmes hybrides, le lecteur a du mal à comprendre à quel niveau agit réellement la logique floue, ou quelle variable déclenche la décision finale. Ici, l'enchaînement est volontairement épuré : deux détecteurs spécialisés fournissent des boîtes, l'IoU sert d'association, le Damage Ratio résume localement la proportion atteinte, puis la logique floue interprète ce ratio. Cette simplicité est un avantage scientifique, parce qu'elle réduit les ambiguïtés d'interprétation.

Elle constitue aussi un avantage pédagogique. Un lecteur qui ne connaît ni les Transformers ni la logique floue peut néanmoins suivre la progression du raisonnement. Il comprend qu'une image contient des pièces, qu'un dommage peut chevaucher une pièce, qu'une proportion est calculée, puis qu'un niveau de gravité est attribué de manière progressive. Dans un mémoire de maîtrise, cette lisibilité est une force, car elle montre que la contribution ne réside pas dans la complexité pour elle-même, mais dans la cohérence entre les composants du système.

Enfin, cette simplicité facilite la défendabilité devant un jury. Chaque étape peut être interrogée séparément : pourquoi DETR ? pourquoi deux branches ? pourquoi l'IoU ? pourquoi un ratio ? pourquoi du flou ? La réponse existe à chaque niveau et s'appuie sur une justification distincte. C'est précisément ce qui permet à DIRF-R d'éviter les erreurs fatales de cohérence que l'on rencontre parfois dans des travaux où la détection, le calcul d'intersection et l'interprétation sont confondus.



# CHAPITRE 4 – Expérimentations

## 4.1 Description du jeu de données

Le corpus utilisé dans ce mémoire comprend plus de 700 images de véhicules intacts et endommagés. Il a été constitué au Canada dans un contexte de collaboration avec Progi [22], puis enrichi par des images publiques provenant principalement de l'Université Stanford [23]. Environ 80 % des images correspondent à des cas réels collectés au Canada en collaboration avec Progi, tandis que les 20 % restants proviennent de sources publiques mobilisées pour accroître la diversité visuelle du corpus.

Cette composition mixte renforce la variété des situations observées : plusieurs angles de prise de vue, différents niveaux d'endommagement, des véhicules intacts servant de contre-exemples, ainsi que des contextes variés d'éclairage, d'arrière-plan et de distance. Après les opérations de filtrage, le corpus se compose d'environ 60 % d'images de véhicules endommagés et de 40 % d'images de véhicules intacts, ce qui reste cohérent avec l'objectif applicatif de DIRF-R.

### 4.1.1 Prétraitement et filtrage des images

Avant l'entraînement, un travail de nettoyage a été effectué sur le corpus. Les images trop floues, de résolution insuffisante, très fortement occultées ou comportant trop peu d'information exploitable ont été écartées. Les doublons et les images dont les dommages étaient difficilement discernables en raison de l'angle de vue ou de la qualité visuelle ont également été supprimés.

Le filtrage a aussi visé à exclure les cas où les pièces du véhicule n'étaient plus suffisamment identifiables, par exemple des véhicules trop sévèrement détruits pour permettre une lecture structurelle fiable. L'objectif était de constituer un jeu de données compatible avec une tâche réaliste d'association pièce-dommage, et non de conserver des cas extrêmes peu interprétables.

### 4.1.2 Annotation manuelle avec Roboflow

Chaque image a été annotée manuellement via la plateforme Roboflow [18]. L'annotation a suivi une taxonomie structurée des pièces du véhicule et des zones de dommages associées. Des boîtes englobantes ont été attribuées à chaque objet annoté. Ce

choix méthodologique est cohérent avec l'architecture proposée, puisque les deux détecteurs DETR manipulent précisément ce type d'annotation en entrée.

L'utilisation de Roboflow a présenté plusieurs avantages pratiques. D'une part, la plateforme facilite la gestion centralisée du corpus, la vérification des annotations et l'export dans différents formats. D'autre part, elle permet d'appliquer des augmentations de données de manière contrôlée et traçable. Dans le présent travail, elle a surtout joué un rôle dans la phase de constitution et d'organisation du corpus, en rendant le processus d'annotation plus homogène.

Conformément au protocole standard retenu sur la plateforme, le jeu de données a été divisé en 70 % pour l'entraînement, 20 % pour la validation et 10 % pour les tests. Cette répartition assure un compromis raisonnable entre quantité de données disponibles pour l'apprentissage et capacité d'évaluer la généralisation du système sur des images non vues.

#### **4.1.3 Taxonomie des classes**

Le détecteur des pièces utilise une taxonomie de composants automobiles structurée. Le détecteur des dommages, en revanche, n'apprend qu'une seule classe, notée « Endommagée ». Ce choix est volontaire. Le mémoire ne cherche pas à classifier les dommages par type visuel détaillé ; il cherche d'abord à les localiser, puis à en interpréter la gravité à partir de leur recouvrement avec les pièces.

Le tableau ci-dessous présente les classes utilisées. La classe « Endommagée » correspond à la branche dommages, tandis que toutes les autres classes appartiennent à la branche pièces. Dans le cas des roues, la logique métier retient également la quantité de roues touchées lorsqu'une ou plusieurs roues sont détectées comme endommagées.

## **4.2 Outils et environnement de travail**

Plusieurs outils ont été mobilisés dans la réalisation du pipeline DIRF-R. Python a constitué le langage de programmation principal pour le développement des scripts, la préparation des données, l'entraînement des modèles et l'évaluation [19]. Son écosystème scientifique, en particulier PyTorch, NumPy, OpenCV et les bibliothèques de manipulation de données, a permis de structurer l'ensemble du travail expérimental.

Google Drive a servi d'espace centralisé pour le stockage et l'organisation des fichiers, facilitant le partage des données, des annotations et des sorties intermédiaires [21]. Google Colaboratory a fourni l'environnement de calcul utilisé pour les entraînements et les expérimentations [20]. L'accès à des GPU a permis de réduire significativement les temps de

calcul, ce qui est particulièrement utile dans le cas de détecteurs à base de Transformers, souvent plus coûteux à entraîner que des modèles plus légers.

Roboflow a enfin joué un rôle clé dans la gestion du corpus annoté. Au-delà de l'annotation, la plateforme a facilité l'export des données, la vérification des classes et l'application d'augmentations simples comme les retournements horizontaux, les variations de luminosité, les rotations légères et le zoom.

### **4.3 Protocole expérimental**

Le protocole expérimental a été conçu de façon à rester cohérent avec la structure du pipeline. Les deux détecteurs DETR ont été entraînés séparément sur leurs jeux d'annotations respectifs. Cette séparation garantit que le détecteur des pièces apprend la structure du véhicule, tandis que le détecteur des dommages apprend uniquement la localisation des zones altérées. Une fois les deux branches entraînées, leurs sorties sont combinées uniquement en phase d'inférence au sein de DIRF-R.

Le processus expérimental comporte donc deux niveaux. Le premier niveau est purement quantitatif : il consiste à évaluer la qualité de chaque détecteur à l'aide de métriques standard de détection. Le second niveau est fonctionnel : il consiste à examiner comment ces sorties peuvent être exploitées par le pipeline complet pour produire une lecture structurée des dommages. Le mémoire met l'accent sur cette articulation, car l'objectif n'est pas seulement d'obtenir des scores, mais de montrer que les scores alimentent un raisonnement utile.

Les augmentations de données retenues sont restées simples et compatibles avec le contexte automobile : retournement horizontal, ajustement de luminosité, variation de contraste, petites rotations et zoom. Ces transformations visent à améliorer la robustesse sans dénaturer la géométrie générale des véhicules.

### **4.4 Métriques d'évaluation**

Les performances des deux détecteurs sont évaluées à l'aide de trois indicateurs principaux : le  $mAP@0,5$ , le  $mAP@50:95$  et le score F1. Le  $mAP@0,5$  mesure la précision moyenne de détection à un seuil d'IoU de 0,5. Le  $mAP@50:95$  est plus exigeant, car il agrège la précision sur plusieurs seuils allant de 0,50 à 0,95. Il fournit donc une lecture plus stricte de la qualité de localisation. Le score F1 résume pour sa part l'équilibre entre précision et rappel.

Les définitions usuelles sont rappelées ci-dessous pour garder le document lisible :

$$\text{Précision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Rappel} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{F1} = 2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$$

Ces métriques n'évaluent pas directement la qualité du raisonnement flou. Elles évaluent la qualité de la base visuelle qui alimente le pipeline. L'apport du module flou se situe en aval, au niveau de l'interprétation des Damage Ratios. C'est pourquoi les résultats de détection doivent être lus comme une condition nécessaire à la pertinence de DIRF-R, mais non comme son unique finalité.

## **4.5 Lecture expérimentale spécifique à DIRF-R**

Une erreur classique, dans les systèmes hybrides, consiste à vouloir résumer toute l'architecture par une seule métrique. Ce n'est pas l'option retenue ici. DIRF-R est une chaîne où les détecteurs fournissent la base des étapes suivantes. Ainsi, une lecture correcte des résultats doit distinguer les performances de détection des performances d'interprétation. Un détecteur plus précis produit une meilleure base pour l'association pièce-dommage, mais l'intérêt du pipeline ne s'arrête pas à ce constat.

Le rôle de la métrique est ici de quantifier la qualité des sorties des deux branches DETR. Le rôle du reste du pipeline est de transformer ces sorties en connaissance interprétable : quelles pièces sont touchées, dans quelle proportion et avec quel degré de gravité. C'est précisément cette hiérarchie entre mesure, association et interprétation qui donne au mémoire sa cohérence.

### **4.5.1 Préparation des annotations pour l'entraînement**

Les annotations produites dans Roboflow ont été exportées dans un format compatible avec le pipeline d'apprentissage de détection d'objets. Dans un cadre DETR, cela suppose de disposer, pour chaque image, des coordonnées des boîtes, des identifiants de classes et des métadonnées minimales nécessaires au chargement du jeu de données. Une partie du travail expérimental a donc consisté à vérifier la cohérence des noms de classes, l'absence d'étiquettes manquantes et la validité des coordonnées.

Cette étape de préparation est souvent sous-estimée dans les travaux appliqués, alors qu'elle conditionne directement la qualité des résultats. Une boîte mal définie, une classe mal orthographiée ou une incohérence entre les versions du corpus peuvent dégrader

l'apprentissage de manière silencieuse. Le choix d'un pipeline propre, avec une séparation claire entre annotations pièces et annotations dommages, a donc été déterminant pour la suite des expérimentations.

#### **4.5.2 Organisation de l'entraînement des deux branches**

Les deux branches DETR ont été entraînées séparément, chacune sur sa propre cible. Cette décision évite que la branche pièces n'apprenne des signaux propres aux dommages et que la branche dommages ne soit pénalisée par la forte diversité des composants structurels. Dans la pratique, l'entraînement séparé rend également le diagnostic expérimental plus simple : si une erreur apparaît, il est plus facile d'identifier si elle provient de la localisation des pièces, de la localisation des dommages ou de l'étape d'association.

Le suivi expérimental a privilégié une logique de stabilisation plutôt qu'une recherche exhaustive d'hyperparamètres. Le but de ce mémoire n'est pas de présenter une optimisation extrême des détecteurs DETR, mais de montrer qu'ils peuvent alimenter correctement le pipeline DIRF-R. Cette précision méthodologique est importante. Elle rappelle que le cœur de la contribution n'est pas un nouveau détecteur, mais une manière cohérente de transformer des détections en interprétations d'expertise.

#### **4.5.3 Du résultat brut au pipeline complet**

Une fois les deux détecteurs entraînés, les sorties brutes sont exploitées en phase d'inférence. Pour chaque image test, la branche pièces et la branche dommages produisent leurs boîtes et leurs scores. Ces sorties sont d'abord filtrées pour ne conserver que les prédictions les plus pertinentes. Elles sont ensuite transmises au module d'association géométrique. Le calcul de l'IoU permet d'identifier quelles pièces et quels dommages se recouvrent réellement. Le Damage Ratio est alors calculé pour chaque pièce concernée, puis transmis au module flou.

Cette procédure permet de passer d'un résultat brut de détection à une représentation organisée. Le lecteur peut ainsi suivre, de manière séquentielle, le chemin d'une image dans le pipeline complet. Cette traçabilité est l'un des avantages majeurs de DIRF-R dans une perspective de validation scientifique et d'usage applicatif.



*Figure 6 : Sortie brute conjointe des détecteurs pièces et dommages avant interprétation finale.*

#### **4.5.4 Pourquoi deux tableaux seulement dans ce mémoire**

Le présent document retient volontairement un nombre réduit de tableaux. Un premier tableau est consacré aux classes annotées, car cette information est indispensable pour comprendre la structure du corpus. Un second tableau est dédié aux métriques, car il synthétise les performances des deux détecteurs. Ce choix éditorial participe à la lisibilité générale du mémoire : l'objectif n'est pas de multiplier les supports visuels, mais de conserver une progression textuelle claire, compréhensible pour un lecteur qui découvre le sujet.

*Tableau 1 – Classes annotées pour les branches Pièces et Dommages*

| <b>ID</b> | <b>Classe</b>          |
|-----------|------------------------|
| 0         | Parechoc avant         |
| 1         | Parechoc arrière       |
| 2         | Calandre               |
| 3         | Aile droite            |
| 4         | Aile gauche            |
| 5         | Capot                  |
| 6         | Parebrise              |
| 7         | Toit                   |
| 8         | Phare avant droit      |
| 9         | Phare avant gauche     |
| 10        | Phare arrière droit    |
| 11        | Phare arrière gauche   |
| 12        | Porte avant droite     |
| 13        | Porte avant gauche     |
| 14        | Porte arrière droite   |
| 15        | Porte arrière gauche   |
| 16        | Rétroviseur droit      |
| 17        | Rétroviseur gauche     |
| 18        | Roues                  |
| 19        | Panneau latéral droit  |
| 20        | Panneau latéral gauche |
| 21        | Coffre                 |
| 22        | Vitre arrière          |
| 23        | Endommagée             |

# CHAPITRE 5 – Résultats

## 5.1 Présentation synthétique des résultats

Les résultats quantitatifs sont rapportés sous la forme d'un unique tableau de synthèse. Ce choix est cohérent avec la logique du mémoire. L'objectif n'est pas de comparer une multitude de variantes ni de présenter une compétition entre architectures, mais d'évaluer les deux détecteurs qui constituent la base du pipeline DIRF-R : le détecteur des pièces et le détecteur des dommages.

Le détecteur des dommages obtient les meilleures valeurs sur l'ensemble des métriques. Cette observation est cohérente avec la structure du problème : la branche dommages ne travaille que sur une seule classe, alors que la branche pièces doit distinguer plusieurs composants visuellement proches. La diversité des pièces, la présence d'occlusions partielles et la variabilité des angles rendent la tâche intrinsèquement plus difficile.

## 5.2 Interprétation détaillée des performances

Les scores du détecteur des pièces montrent que la structuration du véhicule reste une tâche exigeante. Un  $mAP@0,5$  de 0,558 indique que le modèle parvient à localiser correctement une part importante des composants, mais que des marges de progression subsistent, en particulier lorsque l'on considère des seuils de localisation plus stricts. Le  $mAP@50:95$  de 0,289 confirme cette difficulté. Il révèle que certaines boîtes détectées restent approximatives lorsque le critère de localisation devient plus sévère. Le score F1 de 0,312 montre enfin que le compromis entre précision et rappel reste perfectible.

À l'inverse, la branche dommages atteint des scores plus élevés : 0,759 en  $mAP@0,5$ , 0,452 en  $mAP@50:95$  et 0,505 en F1. Ces résultats montrent que le détecteur localise relativement bien les zones de dommages dans le cadre du corpus étudié. Il faut cependant éviter une lecture naïve. Un bon score de détection des dommages ne signifie pas automatiquement que toutes les évaluations locales seront correctes. La qualité finale du pipeline dépend aussi de l'étape d'association. Un dommage peut être bien détecté, mais mal relié à une pièce si cette dernière est mal localisée.

Le tableau des résultats doit donc être lu en articulation avec la méthodologie. Une branche dommages plus forte que la branche pièces signifie que, dans ce corpus, la localisation des altérations est moins problématique que la compréhension détaillée de la



structure du véhicule. Cela renforce l'intérêt d'une architecture en plusieurs étapes : plutôt que de faire porter toute la responsabilité de l'expertise au seul détecteur, DIRF-R introduit une séparation claire entre détection, relation géométrique et interprétation.

### **5.3 Ce que les métriques disent, et ce qu'elles ne disent pas**

Les métriques rapportées dans ce chapitre évaluent exclusivement les sorties des détecteurs DETR. Elles ne mesurent pas directement le comportement du module flou. Ce point doit être explicite pour éviter tout malentendu. Le rôle du module flou n'est pas d'augmenter artificiellement le mAP ou le F1 des détecteurs ; il intervient plus tard, une fois les Damage Ratios calculés. Son apport est de transformer une information continue en une décision plus progressive.

Autrement dit, les métriques disent si la base visuelle du pipeline est suffisamment fiable pour alimenter les étapes suivantes. Elles ne disent pas, à elles seules, si le système produit une expertise de qualité. Pour répondre à cette seconde question, il faut regarder la cohérence du pipeline complet : les pièces détectées, les dommages détectés, l'IoU calculée, le ratio obtenu, puis l'interprétation floue. C'est la combinaison de ces éléments qui fait la valeur de DIRF-R.

### **5.4 Lecture fonctionnelle de DIRF-R**

Sur le plan fonctionnel, DIRF-R permet de passer d'une image brute à une lecture structurée de l'état du véhicule. Lorsqu'une pièce est détectée et qu'une zone de dommage lui est associée par un recouvrement positif, le Damage Ratio fournit immédiatement une mesure de l'atteinte locale. Le module flou transforme alors cette quantité en un niveau de gravité qui peut être compris par un lecteur non spécialiste. Cette chaîne est particulièrement utile dans des scénarios où l'on souhaite expliquer pourquoi une pièce est considérée comme mineure, modérée, sévère ou très sévère.

L'intérêt pratique du pipeline est donc moins de produire un unique score global que d'offrir une interprétation traçable. C'est ce qui distingue une architecture d'aide à l'expertise d'un simple système de détection. Dans un contexte d'assurance, par exemple, on ne cherche pas seulement à savoir si un dommage existe ; on cherche à documenter où il se trouve, quelle pièce il affecte et quelle ampleur il présente.




Figure 7 : Pourcentages de dommages par pièces détectées.

## 5.5 Synthèse

Les résultats confirment que les deux détecteurs fournissent une base exploitable pour le pipeline proposé. Ils montrent aussi que la branche pièces reste le maillon le plus difficile, ce qui est cohérent avec la nature multi classes et structurale du problème. Malgré cette difficulté, les performances obtenues sont suffisantes pour alimenter une chaîne d'analyse où la détection n'est pas la fin du processus, mais le point de départ d'un raisonnement plus large.

En ce sens, les résultats soutiennent l'hypothèse centrale du mémoire : une architecture comme DIRF-R, qui sépare détection, association, quantification et interprétation, constitue une manière cohérente et compréhensible de traiter l'évaluation automatisée des dommages automobiles.

## 5.6 Discussion qualitative et intérêt applicatif

Du point de vue applicatif, les résultats obtenus sont suffisamment structurés pour envisager un usage dans des scénarios d'aide à l'expertise. Le système peut fournir à un opérateur une liste des pièces détectées, mettre en évidence les zones de dommages retenues, puis attribuer un niveau de gravité par composant. Même lorsqu'une décision humaine reste

nécessaire, cette préanalyse peut accélérer la lecture du dossier et uniformiser une partie de l'évaluation.

L'intérêt qualitatif de DIRF-R réside aussi dans le fait qu'il permet de discuter les erreurs. Si une pièce est mal classée, on peut vérifier si le problème provient d'une mauvaise détection de la pièce, d'une mauvaise détection du dommage, d'une absence de recouvrement significatif ou d'une interprétation floue trop sévère. Cette décomposition facilite l'amélioration progressive du système.

*Tableau 2 – Résultats quantitatifs des deux détecteurs DETR utilisés dans DIRF-R*

| <b>Modèle</b>   | <b>mAP@0,5</b> | <b>mAP@50:95</b> | <b>F1</b> |
|-----------------|----------------|------------------|-----------|
| DETR – Pièces   | 0,558          | 0,289            | 0,312     |
| DETR – Dommages | 0,759          | 0,452            | 0,505     |

# **CHAPITRE 6 – Menaces à la validité de l'étude**

## **6.1 Validité interne**

La validité interne de l'étude dépend d'abord de la qualité du corpus et des annotations. Bien que le jeu de données dépasse 700 images, il reste modeste au regard de la diversité réelle des véhicules, des dommages et des contextes visuels. Une erreur d'annotation sur une pièce ou sur une zone de dommage peut affecter à la fois l'apprentissage des détecteurs et le calcul des Damage Ratios. De plus, comme les deux détecteurs sont entraînés séparément, une faiblesse dans l'un d'eux peut se propager à l'ensemble du pipeline.

Une autre limite interne concerne le choix des fonctions d'appartenance floues. Même lorsque leur structure reste simple et compréhensible, ces fonctions traduisent un certain compromis entre souplesse et lisibilité. Un autre réglage pourrait déplacer certaines interprétations de gravité. Cette remarque ne remet pas en cause l'intérêt du module flou, mais elle invite à considérer ses paramètres comme des choix à justifier, et non comme des vérités absolues.

## **6.2 Validité externe**

La validité externe renvoie à la capacité de généralisation du système. Le corpus utilisé a été constitué dans un contexte précis, au Canada, en collaboration avec Progi et l'Université Stanford. Même si les images couvrent plusieurs angles et plusieurs types de scènes, elles ne représentent pas l'ensemble des situations possibles. Des véhicules de marchés différents, des prises de vue dans des conditions météorologiques extrêmes ou des scénarios avec de très fortes occlusions pourraient dégrader les performances.

Il faut également rappeler que le pipeline travaille à partir d'images bidimensionnelles. Des dommages internes, des déformations peu visibles en façade ou des atteintes situées sur des zones non photographiées ne peuvent pas être correctement évalués par le système. L'architecture reste donc pertinente pour une expertise visuelle à partir d'images, mais non pour une inspection exhaustive de tout le véhicule.

## **6.3 Validité de construit**

La validité de construit concerne l'adéquation entre les concepts étudiés et les indicateurs utilisés. Dans ce mémoire, les métriques de détection évaluent bien la qualité de

localisation des pièces et des dommages, mais elles ne capturent pas directement la pertinence du raisonnement flou. Le Damage Ratio, de son côté, constitue une approximation géométrique de la surface atteinte, calculée à partir des boîtes englobantes visibles. Il ne représente pas nécessairement la totalité de l'endommagement réel d'une pièce.

En ce sens, le mémoire assume une définition opératoire de la gravité : il s'agit de la gravité visible, telle qu'elle peut être inférée à partir d'un recouvrement image. Cette définition est cohérente avec le cadre du travail, mais elle doit être explicitement reconnue comme une simplification du concept métier de dommage.

## **6.4 Limites pratiques**

Sur le plan pratique, l'approche reste tributaire de la qualité des images d'entrée. Des images très compressées, trop sombres, prises de trop loin ou comportant une partie seulement du véhicule peuvent réduire l'utilité du pipeline. De plus, la méthode suppose que la surface visible d'une pièce est un proxy raisonnable de son atteinte, ce qui n'est pas toujours vrai lorsque le dommage se prolonge hors champ ou se manifeste surtout par une déformation interne.

Ces limites ne rendent pas le système inutilisable ; elles rappellent simplement qu'il s'agit d'un outil d'aide à l'évaluation fondé sur l'analyse visuelle de photographies. Le jugement expert garde donc sa place, surtout dans les dossiers complexes.

# CHAPITRE 7 – Conclusion

## 7.1 Bilan général

Ce mémoire a proposé DIRF-R, un pipeline d'évaluation automatisée des dommages automobiles articulé autour de quatre étapes clairement séparées : Detection, Intersection, Ratio et Fuzzy Reasoning. L'architecture repose sur deux détecteurs DETR indépendants, l'un pour les pièces du véhicule et l'autre pour les zones de dommages. Leurs sorties sont mises en relation par une mesure géométrique réelle d'intersection, puis transformées en Damage Ratios interprétés à l'aide d'un module de logique floue.

La principale force de cette approche tient à sa lisibilité méthodologique. Le système ne cherche pas à cacher la décision dans une seule boîte noire. Il explicite au contraire les différentes transformations qui mènent d'une image à une évaluation. Cette structuration rend le pipeline plus compréhensible pour un lecteur généraliste, plus défendable dans un cadre académique, et plus pertinent dans un contexte applicatif où l'explication du résultat est importante.

## 7.2 Apports scientifiques et méthodologiques

Sur le plan scientifique, le mémoire montre qu'un positionnement fondé sur DETR et sur la logique floue est pertinent pour traiter l'évaluation des dommages automobiles. Le recours à deux détecteurs spécialisés évite de mélanger la structure du véhicule et les zones d'altération. L'association par IoU fournit un mécanisme simple et objectivable pour relier les deux branches. Le Damage Ratio introduit une variable intermédiaire facile à interpréter. Enfin, le module flou permet d'éviter une décision trop rigide et rapproche le système d'un raisonnement d'expertise.

Sur le plan méthodologique, DIRF-R apporte aussi une réponse à un problème fréquent dans les mémoires techniques : la confusion entre performance algorithmique et utilité du système. Ici, les métriques de détection sont clairement distinguées du raisonnement final. Cette séparation renforce la cohérence de l'ensemble et limite les interprétations abusives.

## 7.3 Limites et perspectives

Plusieurs prolongements sont envisageables. Le premier concerne l'augmentation du corpus et la diversification des véhicules et des contextes de prise de vue. Un corpus plus vaste permettrait de renforcer la robustesse des détecteurs, en particulier pour la branche pièces. Le

deuxième prolongement concerne l'amélioration de la représentation géométrique. Le calcul du Damage Ratio à partir de boîtes englobantes reste simple, mais pourrait être affiné à l'avenir par des approches de segmentation plus précises. Le troisième prolongement porte sur la validation métier. Une confrontation systématique des sorties du pipeline avec des évaluations humaines expertes permettrait de mieux calibrer les fonctions d'appartenance floues et les règles d'agrégation globale.

Enfin, il serait intéressant d'explorer des variantes DETR plus avancées, telles que Deformable DETR, Conditional DETR ou d'autres modèles spécialisés pour les petits objets, afin d'améliorer la qualité de la branche pièces sans rompre la philosophie générale du pipeline. Ces perspectives confirment que DIRF-R constitue une base solide, mais encore perfectible, pour des systèmes futurs d'aide à l'expertise automobile.

## **7.4 Conclusion finale**

En conclusion, l'étude montre qu'un pipeline combinant deux détecteurs DETR, une association géométrique explicite par IoU, un Damage Ratio local et une interprétation floue graduelle constitue une approche crédible pour l'évaluation automatisée des dommages automobiles. Le nom DIRF-R ne désigne pas seulement une chaîne technique ; il résume une manière cohérente de penser le problème. Détecter, relier, quantifier puis interpréter : telle est la logique générale qui structure ce mémoire.

Cette organisation permet d'obtenir un document plus solide face à un jury, car chaque étape est justifiée, limitée et reliée à un besoin précis. C'est aussi ce qui rend le travail accessible à un lecteur non spécialiste : le système n'est pas présenté comme une simple collection de modèles, mais comme un raisonnement progressif appliqué aux images automobiles.

# Références

- [1] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov and S. Zagoruyko, “End-to-End Object Detection with Transformers,” European Conference on Computer Vision (ECCV), 2020.
- [2] K. He, X. Zhang, S. Ren and J. Sun, “Deep Residual Learning for Image Recognition,” IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- [3] A. Vaswani et al., “Attention Is All You Need,” Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [4] L. A. Zadeh, “Fuzzy Sets,” Information and Control, vol. 8, no. 3, pp. 338–353, 1965.
- [5] D. Dubois and H. Prade, Fuzzy Sets and Systems: Theory and Applications, Academic Press, 1980.
- [6] R. R. Yager and D. P. Filev, Essentials of Fuzzy Modeling and Control, John Wiley & Sons, 1994.
- [7] Y. Li et al., “Transformer for Object Detection: Review and Benchmark,” Engineering Applications of Artificial Intelligence, vol. 126, 107021, 2023.
- [8] X. Zhu et al., “Deformable DETR: Deformable Transformers for End-to-End Object Detection,” International Conference on Learning Representations (ICLR), 2021.
- [9] S. Liu et al., “DAB-DETR: Dynamic Anchor Boxes Are Better Queries for DETR,” International Conference on Learning Representations (ICLR), 2022.
- [10] F. Li et al., “DN-DETR: Accelerate DETR Training by Introducing Query DeNoising,” IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.
- [11] D. Meng et al., “Conditional DETR for Fast Training Convergence,” IEEE/CVF International Conference on Computer Vision (ICCV), 2021.
- [12] K. Pasupa et al., “Evaluation of Deep Learning Algorithms for Semantic Segmentation of Car Parts,” Complex & Intelligent Systems, vol. 8, no. 5, pp. 3613–3625, 2022.



- [13] N. A. Mohammed, M. Y. Potrus and A. M. Ali, "Deep Learning Based Car Damage Classification and Cost Estimation," Zanco Journal of Pure and Applied Sciences, vol. 35, no. 1, pp. 1–9, 2023.
- [14] J. Qaddour and S. A. Siddiqa, "Automatic Damaged Vehicle Estimator Using Enhanced Deep Learning Algorithm," Intelligent Systems with Applications, vol. 18, 2023.
- [15] R. Van Ruitenbeek and S. Bhulai, "Convolutional Neural Networks for Vehicle Damage Detection," Machine Learning with Applications, vol. 9, 100332, 2022.
- [16] I. Ullah and K. Yow, "Automated Vehicle Dent Detection Using Hybrid Image Processing and Fuzzy Decision Making," Mechatronics and Intelligent Transportation Systems, vol. 4, no. 1, pp. 49–60, 2025.
- [17] T.-Y. Lin et al., "Microsoft COCO: Common Objects in Context," European Conference on Computer Vision (ECCV), 2014.
- [18] Roboflow, "Roboflow Platform," documentation consultée en 2025.
- [19] Python Software Foundation, "Python Language Reference," documentation consultée en 2025.
- [20] Google, "Google Colaboratory," documentation consultée en 2025.
- [21] Google, "Google Drive," documentation consultée en 2025.
- [22] Progi, "Solutions technologiques pour l'assurance automobile," documentation institutionnelle consultée en 2025.
- [23] Stanford University, "Stanford Cars Dataset and related public automotive image resources," documentation consultée en 2025.
- [24] R. Padilla, S. L. Netto and E. A. B. da Silva, "A Survey on Performance Metrics for Object-Detection Algorithms," International Conference on Systems, Signals and Image Processing, 2020.

# **Annexes**

## **Annexe A – Conventions d’annotation du corpus**

Cette annexe peut regrouper la convention de nommage des classes, les règles d’annotation retenues pour les pièces et les dommages, ainsi que quelques exemples de cas limites observés lors de l’annotation manuelle dans Roboflow.

## **Annexe B – Exemples qualitatifs de sorties du pipeline DIRF-R**

Cette annexe peut accueillir des sorties qualitatives représentatives du pipeline : image annotée par les deux détecteurs, liste des pièces endommagées, Damage Ratios obtenus, catégories floues attribuées, ainsi que des cas exploratoires comme la distinction gauche/droite.

## **Annexe C – Paramètres indicatifs du module flou**

Cette annexe peut présenter les paramètres numériques retenus pour les fonctions d’appartenance, les bornes indicatives des niveaux de gravité et quelques exemples de lecture des degrés d’appartenance, sans alourdir le corps principal du mémoire.